

# Econometria Aplicada

Regressão linear: simples e múltipla

---

João Ricardo Costa Filho

# Econometria Aplicada

---

O que vocês esperam deste curso?

*"The most important questions of life are, for the most part, really only problems in probability."*

Laplace (1812)

*"In God we trust. All others must bring data."*

William Edwards Deming

## Tipos de dados

- Cross-section.

# Tipos de dados

- Cross-section.
- Dados em painel.

# Tipos de dados

- Cross-section.
- Dados em painel.
- Série de tempo



- Aula 1 - Regressão linear: simples e múltipla

## A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais

# A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)

# A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)
- Aula 4 - Variáveis Instrumentais

# A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)
- Aula 4 - Variáveis Instrumentais
- Aula 5 - Modelos com dados em painel

# A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)
- Aula 4 - Variáveis Instrumentais
- Aula 5 - Modelos com dados em painel
- Aula 6 - Introdução à séries temporais

## A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)
- Aula 4 - Variáveis Instrumentais
- Aula 5 - Modelos com dados em painel
- Aula 6 - Introdução à séries temporais
- Aula 7 - Modelos ARIMA

## A nossa jornada

- Aula 1 - Regressão linear: simples e múltipla
- Aula 2 - Regressão linear múltipla e formas funcionais
- Aula 3 - Modelos de probabilidade (Probit e Logit)
- Aula 4 - Variáveis Instrumentais
- Aula 5 - Modelos com dados em painel
- Aula 6 - Introdução à séries temporais
- Aula 7 - Modelos ARIMA
- Aula 8 - Discussão sobre os trabalhos



Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]
- Aula 3 - Modelos de probabilidade (Probit e Logit) [capítulo 17]

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]
- Aula 3 - Modelos de probabilidade (Probit e Logit) [capítulo 17]
- Aula 4 - Variáveis Instrumentais [capítulo 15]

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]
- Aula 3 - Modelos de probabilidade (Probit e Logit) [capítulo 17]
- Aula 4 - Variáveis Instrumentais [capítulo 15]
- Aula 5 - Modelos com dados em painel [capítulo 13]

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]
- Aula 3 - Modelos de probabilidade (Probit e Logit) [capítulo 17]
- Aula 4 - Variáveis Instrumentais [capítulo 15]
- Aula 5 - Modelos com dados em painel [capítulo 13]
- Aula 6 - Introdução à séries temporais [capítulo 18]

Wooldridge, J. M. (2006). Introdução à econometria: uma abordagem moderna. Pioneira Thomson Learning.

- Aula 1 - Regressão linear: simples e múltipla [capítulo 2, 3 e 4]
- Aula 2 - Regressão linear múltipla e formas funcionais [capítulo 2, 3 e 4]
- Aula 3 - Modelos de probabilidade (Probit e Logit) [capítulo 17]
- Aula 4 - Variáveis Instrumentais [capítulo 15]
- Aula 5 - Modelos com dados em painel [capítulo 13]
- Aula 6 - Introdução à séries temporais [capítulo 18]
- Aula 7 - Modelos ARIMA [capítulo 18]

- **Vocês são os protagonistas do próprio aprendizado.**



- **Vocês são os protagonistas do próprio aprendizado.**
- Há evidências de que os alunos aprendem mais com métodos ativos,

- **Vocês são os protagonistas do próprio aprendizado.**
- Há evidências de que os alunos aprendem mais com métodos ativos, embora muitas vezes prefiram aulas meramente expositivas.

- **Vocês são os protagonistas do próprio aprendizado.**
- Há evidências de que os alunos aprendem mais com métodos ativos, embora muitas vezes prefiram aulas meramente expositivas. Surge o nosso primeiro conflito.

- **Vocês são os protagonistas do próprio aprendizado.**
- Há evidências de que os alunos aprendem mais com métodos ativos, embora muitas vezes prefiram aulas meramente expositivas. Surge o nosso primeiro conflito.
- A importância de (saber) resolver problemas.

- **Vocês são os protagonistas do próprio aprendizado.**
- Há evidências de que os alunos aprendem mais com métodos ativos, embora muitas vezes prefiram aulas meramente expositivas. Surge o nosso primeiro conflito.
- A importância de (saber) resolver problemas.
- **Marquem uma conversa comigo!** (quero saber sobre você, seu interesse no programa e o seu **plano de estudos** para a disciplina).



- Atividades em sala.

- Atividades em sala.
- Trabalho – Aplicação.



- Atividades em sala.
- Trabalho – Aplicação.
- Fórum de discussão.

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado.

## Trabalho

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação**

## Trabalho

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação** de (i) uma pergunta,

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação** de (i) uma pergunta, (ii) descrição e análise dos dados que serão utilizados para responder essa pergunta,

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação** de (i) uma pergunta, (ii) descrição e análise dos dados que serão utilizados para responder essa pergunta, (iii) estimativas econométricas

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação** de (i) uma pergunta, (ii) descrição e análise dos dados que serão utilizados para responder essa pergunta, (iii) estimativas econométricas e (iv) conclusões.

- O **principal produto da disciplina** é desenvolver a capacidade de desenhar e implementar um projeto aplicado. Por isso, o trabalho consiste na **apresentação** de (i) uma pergunta, (ii) descrição e análise dos dados que serão utilizados para responder essa pergunta, (iii) estimativas econométricas e (iv) conclusões.
- A última aula da disciplina será destinada à apresentação do trabalho e entrega (apresentação – um arquivo no formato ‘pdf’ – e códigos + dados, enviados pelo Teams).
- Sugestão: acesse a “Base dos dados” para encontrar dados para a economia brasileira que ajudem a responder a pergunta de pesquisado do trabalho.





- Linguagem: R
- Como?
  - RStudio
  - Google Colab:  
<https://colab.research.google.com/#create=true&language=r>

# A regressão linear

---

## Motivação (tudo começa com uma pergunta)

Qual é a exposição de ações individuais ao portfólio de mercado?

## Visualização dos dados (super importante!)

Vamos coletar os dados e "olhar" para eles.

Por que visualizar os dados é tão importante assim?

## O quarteto de Anscombe

---

## O quarteto de Anscombe (Anscombe 1973)

Imagine quatro conjuntos de dados.



## O quarteto de Anscombe (Anscombe 1973)

Imagine quatro conjuntos de dados. Em cada um deles, temos duas variáveis ( $X$  e  $Y$ ). Em todos, temos. . .

## O quarteto de Anscombe (Anscombe 1973)

Imagine quatro conjuntos de dados. Em cada um deles, temos duas variáveis ( $X$  e  $Y$ ). Em todos, temos...

- ...a mesma média e o mesmo desvio-padrão de  $X$ .

## O quarteto de Anscombe (Anscombe 1973)

Imagine quatro conjuntos de dados. Em cada um deles, temos duas variáveis ( $X$  e  $Y$ ). Em todos, temos...

- ...a mesma média e o mesmo desvio-padrão de  $X$ .
- ...a mesma média e o mesmo desvio-padrão de  $Y$ .

## O quarteto de Anscombe (Anscombe 1973)

Imagine quatro conjuntos de dados. Em cada um deles, temos duas variáveis ( $X$  e  $Y$ ). Em todos, temos...


- ...a mesma média e o mesmo desvio-padrão de  $X$ .
- ...a mesma média e o mesmo desvio-padrão de  $Y$ .
- ...a mesma correlação entre  $X$  e  $Y$ .

## O quarteto de Anscombe (Anscombe 1973)


Imagine quatro conjuntos de dados. Em cada um deles, temos duas variáveis ( $X$  e  $Y$ ). Em todos, temos...

- ...a mesma média e o mesmo desvio-padrão de  $X$ .
- ...a mesma média e o mesmo desvio-padrão de  $Y$ .
- ...a mesma correlação entre  $X$  e  $Y$ .
- ...os mesmos coeficientes estimados para uma regressão linear de  $Y$  em  $X$ .


## O quarteto de Anscombe - olhem para os dados!



## O quarteto de Anscombe - olhem para os dados!




## O quarteto de Anscombe - olhem para os dados!





## O quarteto de Anscombe - olhem para os dados!



Voltemos à questão dos retornos das ações frente ao retorno do mercado.

Como responder a questão que motivou a  
nossa análise?

## A regressão linear

Assuma que possamos relacionar os retornos diários de uma ação “a” com os retornos diários do Ibovespa da seguinte forma:

$$r_i^a = \beta_0 + \beta_1 r_i^{\text{ibov}} + \varepsilon_i$$

## A regressão linear

Assuma que possamos relacionar os retornos diários de uma ação “a” com os retornos diários do Ibovespa da seguinte forma:

$$r_i^a = \beta_0 + \beta_1 r_i^{\text{ibov}} + \varepsilon_i$$

O que os parâmetros significam?

## A regressão linear

Assuma que possamos relacionar os retornos diários de uma ação “a” com os retornos diários do Ibovespa da seguinte forma:

$$r_i^a = \beta_0 + \beta_1 r_i^{\text{ibov}} + \varepsilon_i$$

O que os parâmetros significam? Como estimá-los?

## Regressão linear com MQO

Assuma que busquemos um estimador que minimize o erro quadrado. Por quê erro quadrado?

## Regressão linear com MQO

Assuma que busquemos um estimador que minimize o erro quadrado. Por quê erro quadrado?

- Erro:  $\varepsilon_i = r_i^a - \beta_0 - \beta_1 r_i^{\text{ibov}}$ .



## Regressão linear com MQO

Assuma que busquemos um estimador que minimize o erro quadrado. Por quê erro quadrado?

- Erro:  $\epsilon_i = r_i^a - \beta_0 - \beta_1 r_i^{\text{ibov}}$ .
- $\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (r_i^a - \hat{\beta}_0 - \hat{\beta}_1 r_i^{\text{ibov}})^2$

## Regressão linear com MQO

Assuma que busquemos um estimador que minimize o erro quadrado. Por quê erro quadrado?

- Erro:  $\epsilon_i = r_i^a - \beta_0 - \beta_1 r_i^{\text{ibov}}$ .
- $\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (r_i^a - \hat{\beta}_0 - \hat{\beta}_1 r_i^{\text{ibov}})^2$ 
  - $$\hat{\beta}_1 = \frac{\sum_{i=1}^n (r_i^{\text{ibov}} - \overline{r^{\text{ibov}}}) (r_i^a - \overline{r^a})}{\sum_{i=1}^n (r_i^{\text{ibov}} - \overline{r^{\text{ibov}}})^2}$$

## Regressão linear com MQO

Assuma que busquemos um estimador que minimize o erro quadrado. Por quê erro quadrado?

- Erro:  $\varepsilon_i = r_i^a - \beta_0 - \beta_1 r_i^{\text{ibov}}$ .
- $\min_{\hat{\beta}_0, \hat{\beta}_1} \sum_{i=1}^n (\varepsilon_i)^2 = \sum_{i=1}^n (r_i^a - \hat{\beta}_0 - \hat{\beta}_1 r_i^{\text{ibov}})^2$ 
  - $\hat{\beta}_1 = \frac{\sum_{i=1}^n (r_i^{\text{ibov}} - \overline{r^{\text{ibov}}}) (r_i^a - \overline{r^a})}{\sum_{i=1}^n (r_i^{\text{ibov}} - \overline{r^{\text{ibov}}})^2}$
  - $\hat{\beta}_0 = \overline{r^a} - \hat{\beta}_1 \overline{r^{\text{ibov}}}$

## Regressão linear com MQO

Genericamente

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = \text{corr}(X, Y) \frac{s_X}{s_Y}$$

## Regressão linear com MQO

Genericamente

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = \text{corr}(X, Y) \frac{s_X}{s_Y}$$

e

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Vamos estimar as regressões!

# Inferência

---

Vocês aceitam errar quantas vezes para cada 100 tentativas?



Como verificar se a associação entre as variáveis é estatisticamente significativa?

Como verificar se a associação entre as variáveis é estatisticamente significativa? Realizados testes de hipótese sobre os parâmetros!

Como verificar se a associação entre as variáveis é estatisticamente significativa? Realizados testes de hipótese sobre os parâmetros!

- Para  $\hat{\beta}_0$ :

Como verificar se a associação entre as variáveis é estatisticamente significativa? Realizados testes de hipótese sobre os parâmetros!

- Para  $\hat{\beta}_0$ :

$$\mathcal{H}_0 : \beta_0 = 0$$

$$\mathcal{H}_a : \beta_0 \neq 0$$

Como verificar se a associação entre as variáveis é estatisticamente significativa? Realizados testes de hipótese sobre os parâmetros!

- Para  $\hat{\beta}_0$ :

$$\mathcal{H}_0 : \beta_0 = 0$$

$$\mathcal{H}_a : \beta_0 \neq 0$$

- Para  $\hat{\beta}_1$ :

$$\mathcal{H}_0 : \beta_1 = 0$$

$$\mathcal{H}_a : \beta_1 \neq 0$$

(Não precisam ser apenas com  $\neq$  e nem com zero!)

Vamos simular o comportamento de  $\beta_0$  e  $\beta_1$  em diferentes amostras?

## Vamos simular para entender o que significa um teste de hipótese

Imagine que tenhamos 500 amostras de tamanho 200 com duas variáveis,  $X$  e  $Y$ .

## Vamos simular para entender o que significa um teste de hipótese

Imagine que tenhamos 500 amostras de tamanho 200 com duas variáveis,  $X$  e  $Y$ . E que saibamos que  $Y_i = 2 + 3X_i + \epsilon_i$ .



## Vamos simular para entender o que significa um teste de hipótese

Imagine que tenhamos 500 amostras de tamanho 200 com duas variáveis,  $X$  e  $Y$ . E que saibamos que  $Y_i = 2 + 3X_i + \epsilon_i$ . Ou seja, que  $\beta_0 = 2$  e  $\beta_1 = 3$ .

## Vamos simular para entender o que significa um teste de hipótese

Imagine que tenhamos 500 amostras de tamanho 200 com duas variáveis,  $X$  e  $Y$ . E que saibamos que  $Y_i = 2 + 3X_i + \epsilon_i$ . Ou seja, que  $\beta_0 = 2$  e  $\beta_1 = 3$ . Quais seriam os resultados dos estimadores ( $\hat{\beta}_0$  e  $\hat{\beta}_1$ ) em cada uma delas?

## Vamos simular para entender o que significa um teste de hipótese

Imagine que tenhamos 500 amostras de tamanho 200 com duas variáveis,  $X$  e  $Y$ . E que saibamos que  $Y_i = 2 + 3X_i + \epsilon_i$ . Ou seja, que  $\beta_0 = 2$  e  $\beta_1 = 3$ . Quais seriam os resultados dos estimadores ( $\hat{\beta}_0$  e  $\hat{\beta}_1$ ) em cada uma delas? Podemos identificar algum padrão?

## Vamos simular para entender o que significa um teste de hipótese

```
# Para replicarmos as variáveis pseudo aleatórias
```

```
set.seed(1301)
```

```
# Definindo os parâmetros
```

```
amostras <- 500 # número de amostras
```

```
n <- 200 # tamanho de cada amostra
```

```
b0 <- 2
```

```
b1 <- 3
```

## Vamos simular para entender o que significa um teste de hipótese

```
# Criando as amostras
```

```
X <- replicate( amostras, rnorm( n, mean = 10, sd = 2 ) )
```

```
e <- replicate( amostras, rnorm( n, mean = 0, sd = 1 ) )
```

```
Y <- b0 + b1 * X + e
```

## Vamos simular para entender o que significa um teste de hipótese


```
# Fazendo as regressões
```

```
regressoes <- lapply( 1:amostras,  
                     function(i) lm( Y[ , i ] ~ X[ , i ] ) )
```

```
betas <- sapply(regressoes,  
               function(modelo) coef(modelo)[2])
```

```
beta1 = mean( betas )
```

# Vamos simular para entender o que significa um teste de hipótese



Ou seja, tanto  $\hat{\beta}_0$  quanto  $\hat{\beta}_1$  são **estatísticas** (i.e. funções dos valores amostrais) e cada estatística possui uma **distribuição**. Em função disso, podemos (i) definir um nível de significância e (ii) fazer um teste de hipótese sobre o parâmetro de interesse.





## Teste t

- Para  $\hat{\beta}_1$ :

- Para  $\hat{\beta}_1$ :

$$\mathcal{H}_0 : \beta_1 = \mu$$

$$\mathcal{H}_a : \beta_1 \neq \mu$$

- Para  $\hat{\beta}_1$ :

$$\mathcal{H}_0 : \beta_1 = \mu$$

$$\mathcal{H}_a : \beta_1 \neq \mu$$

A estatística do teste é dada por:

$$t_{\hat{\beta}_1} = \frac{\hat{\beta}_1 - \mu}{se(\hat{\beta}_1)}$$

porque  $t_{\hat{\beta}_1} \sim T_{n-k-1}$ .

Como fica o teste para as regressões que estimamos?

Quanto os modelos explicam a variação dos retornos diários das empresas?

## Goodness of fit

Quanto eu consigo explicar sobre a variação dos retorno diários das ações com base nas variações do portfólio de mercado?



Quanto eu consigo explicar sobre a variação dos retorno diários das ações com base nas variações do portfólio de mercado?

- Do total da soma (dos quadrados) dos resíduos,  
$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = (n - 1)s_Y^2 \dots$$

Quanto eu consigo explicar sobre a variação dos retorno diários das ações com base nas variações do portfólio de mercado?

- Do total da soma (dos quadrados) dos resíduos,

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = (n - 1)s_Y^2 \dots$$

- ... uma parte é explicada pelo modelo,

$$\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = s_{\hat{Y}}^2 \dots$$

Quanto eu consigo explicar sobre a variação dos retorno diários das ações com base nas variações do portfólio de mercado?

- Do total da soma (dos quadrados) dos resíduos,  
 $\sum_{i=1}^n (Y_i - \bar{Y})^2 = (n - 1)s_Y^2 \dots$
- ... uma parte é explicada pelo modelo,  
 $\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = s_{\hat{Y}}^2 \dots$
- ... e outra parte é explicada pelo erro,  $\sum_{i=1}^n (\varepsilon_i - 0)^2 = s_{\varepsilon}^2 \dots$

Quanto eu consigo explicar sobre a variação dos retorno diários das ações com base nas variações do portfólio de mercado?

- Do total da soma (dos quadrados) dos resíduos,  
 $\sum_{i=1}^n (Y_i - \bar{Y})^2 = (n-1)s_Y^2 \dots$
- ... uma parte é explicada pelo modelo,  
 $\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = s_{\hat{Y}}^2 \dots$
- ... e outra parte é explicada pelo erro,  $\sum_{i=1}^n (\varepsilon_i - 0)^2 = s_{\varepsilon}^2 \dots$
- Assim, podemos definir uma estatística que avalia quão aderente é o modelo aos dados:  $R^2 = \frac{s_{\hat{Y}}^2}{s_Y^2} = 1 - \frac{s_{\varepsilon}^2}{s_Y^2}$

**Por quê MQO?**

---

- Sob algumas hipóteses (Gauss-Markov), o estimador de mínimos quadrados é **BLUE** (*best linear unbiased estimator*). Mesmo sem assumirmos a normalidade dos erros!

- Sob algumas hipóteses (Gauss-Markov), o estimador de mínimos quadrados é **BLUE** (*best linear unbiased estimator*). Mesmo sem assumirmos a normalidade dos erros!
- Sob a hipótese de normalidade dos erros, o estimador de MQO é o mais eficiente entre os estimadores lineares e não-lineares (Cramér–Rao)!

- Sob algumas hipóteses (Gauss-Markov), o estimador de mínimos quadrados é **BLUE** (*best linear unbiased estimator*). Mesmo sem assumirmos a normalidade dos erros!
- Sob a hipótese de normalidade dos erros, o estimador de MQO é o mais eficiente entre os estimadores lineares e não-lineares (Cramér–Rao)!
- E quais são essas hipóteses?



# Hipótesis

# Hipóteses

- **Linearidade:**  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  (linear nos parâmetros, as variáveis podem ser não-lineares).

# Hipóteses

- **Linearidade:**  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  (linear nos parâmetros, as variáveis podem ser não-lineares).
- **Exogeneidade:**  $E[\varepsilon_i | X_i] = E[\varepsilon_i] = 0$ .

# Hipóteses

- **Linearidade:**  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  (linear nos parâmetros, as variáveis podem ser não-lineares).
- **Exogeneidade:**  $E[\varepsilon_i | X_i] = E[\varepsilon_i] = 0$ .
- **Multicolinearidade não-perfeita:** se tivermos mais de uma variável  $X$  (e.g.  $X_1, X_2, \dots, X_k$ ), elas não podem ser perfeitamente correlacionadas.

# Hipóteses

- **Linearidade:**  $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$  (linear nos parâmetros, as variáveis podem ser não-lineares).
- **Exogeneidade:**  $E[\varepsilon_i | X_i] = E[\varepsilon_i] = 0$ .
- **Multicolinearidade não-perfeita:** se tivermos mais de uma variável  $X$  (e.g.  $X_1, X_2, \dots, X_k$ ), elas não podem ser perfeitamente correlacionadas.
- **Homocedasticidade:**  $Var[\varepsilon_i | X_i] = \sigma^2$  e  $Cov[\varepsilon_i, \varepsilon_j | X_i] = 0$ .

# Exogeneidade

Esse é um ponto crucial para nós.

Esse é um ponto crucial para nós.

- O termo erro ( $\varepsilon_i$ ) inclui, por definição, tudo o que não está no modelo. Ele **não** pode influenciar as variáveis explicativas (X). Se isso acontecer, é porque temos:
  - Variáveis omitidas.



Esse é um ponto crucial para nós.

- O termo erro ( $\varepsilon_i$ ) inclui, por definição, tudo o que não está no modelo. Ele **não** pode influenciar as variáveis explicativas (X). Se isso acontecer, é porque temos:
  - Variáveis omitidas.
  - Erro de mensuração das variáveis explicativas.

Esse é um ponto crucial para nós.

- O termo erro ( $\varepsilon_i$ ) inclui, por definição, tudo o que não está no modelo. Ele **não** pode influenciar as variáveis explicativas (X). Se isso acontecer, é porque temos:
  - Variáveis omitidas.
  - Erro de mensuração das variáveis explicativas.
  - Simultaneidade



Sob exogeneidade e Multicolinearidade não-perfeita, o estimador de MQO é **consistente** e **não-viesado**.

Sob exogeneidade e Multicolinearidade não-perfeita, o estimador de MQO é **consistente** e **não-viesado**.

- Consistência:  $\text{plim}_{n \rightarrow \infty} |\hat{\beta}_1 - \beta| = 0$ .

Sob exogeneidade e Multicolinearidade não-perfeita, o estimador de MQO é **consistente** e **não-viesado**.

- Consistência:  $\text{plim}_{n \rightarrow \infty} |\hat{\beta}_1 - \beta| = 0$ .
- Não-viesado:  $E[\hat{\beta}_1] = \beta$

# Regressão múltipla

---

Será que podemos melhorar a maneira como respondemos a questão proposta?



# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada,

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse e (iii) variáveis de controle.

## Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse e (iii) variáveis de controle.
- A diferença é que agora temos diversas dimensões, mas continuamos com uma reta que se ajusta ao minimizar a soma do erro quadrado.

# Regressão múltipla

## Regressão múltipla

$$Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_k X_{k,i} + \varepsilon_i.$$

# Regressão múltipla

$$Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_k X_{k,i} + \varepsilon_i.$$

[Clique aqui para a matemática do estimador](#)



Quais outras perguntas podemos responder com uma regressão múltipla?

## $R^2$ e $R^2$ ajustado

## $R^2$ e $R^2$ ajustado

- Como podemos comparar modelos? A estatística  $R^2$  **não** é uma boa maneira.

## $R^2$ e $R^2$ ajustado

- Como podemos comparar modelos? A estatística  $R^2$  **não** é uma boa maneira.
- Podemos utilizar o  $R^2$  ajustado, no entanto:

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1} \quad (1)$$

onde  $n$  é o número de observações da amostra e  $k$  representa o número de variáveis independentes do modelo.

Podemos testar a significância conjunta dos estimadores:

$$\mathcal{H}_0 : \beta_0 = \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$\mathcal{H}_a : \beta_j \neq 0, \text{ para menos um valor de } j$$

$$F = \frac{\sum_i \epsilon_i^2 - \sum_i e_i^2}{\sum_i e_i^2} \frac{n - k_2}{k_2 - k_1} \sim F_{k_2 - k_1, n - k_2} \quad (2)$$

onde  $k_2$  é o número de parâmetros do modelo irrestrito e  $k_1$  o número de parâmetros do modelo restrito.

# Apêndice

---

## Regressão múltipla – estimador de MQO

- $\min_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i})^2$

## Regressão múltipla – estimador de MQO

- $\min_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i})^2$ 
  - $\hat{\beta}_1 = \frac{\rho_{X_1,Y} - \rho_{X_1,X_2} \times \rho_{X_2,Y}}{1 - \rho_{X_1,X_2}^2}$
  - $\hat{\beta}_2 = \frac{\rho_{X_2,X_1} - \rho_{X_1,X_2} \times \rho_{X_1,Y}}{1 - \rho_{X_1,Y}^2}$
  - $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2$

◀ Retornar



## Regressão múltipla – estimador de MQO

E com mais variáveis?

## Regressão múltipla – estimador de MQO

E com mais variáveis? Vamos utilizar álgebra matricial! Podemos escrever o modelo da seguinte forma:

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ \vdots \\ Y_n \end{bmatrix}_{n \times 1} = \begin{bmatrix} 1 & X_{11} & X_{21} & \dots & X_{k1} \\ 1 & X_{12} & X_{22} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_{1n} & X_{2n} & \dots & X_{kn} \end{bmatrix}_{n \times k} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \vdots \\ \beta_n \end{bmatrix}_{k \times 1} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \vdots \\ \epsilon_n \end{bmatrix}_{n \times 1}$$

Ou, simplesmente

$$Y = X\beta + \epsilon.$$

## Regressão múltipla – estimador de MQO

O resíduo (não o erro) pode ser definido como

$$e = Y - X\beta \quad (3)$$

A soma dos quadrados dos resíduos pode ser escrita como:

$$\begin{bmatrix} e_1 & e_2 & \dots & e_n \end{bmatrix}_{1 \times n} \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}_{n \times 1} = [e_1 \times e_1 + e_2 \times e_2 + \dots + e_n \times e_n]_{1 \times 1}$$

## Regressão múltipla – estimador de MQO

$$\begin{aligned}e'e &= (\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) \\&= \mathbf{Y}'\mathbf{Y} - \hat{\beta}'\mathbf{X}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\hat{\beta} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta} \\&= \mathbf{Y}'\mathbf{Y} - 2\hat{\beta}'\mathbf{X}'\mathbf{Y} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta}\end{aligned}\tag{4}$$

Assim, temos

$$\frac{\partial e'e}{\partial \hat{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = 0\tag{5}$$

é igual a

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{Y}).$$

Anscombe, Francis J. 1973. “Graphs in Statistical Analysis.” *The American Statistician* 27 (1): 17–21.