

Econometria de Séries Temporais

O modelo Autorregressivo (AR)

João Ricardo Costa Filho

"The most important questions of life are, for the most part, really only problems in probability."

Laplace (1812)

"In God we trust. All others must bring data."

William Edwards Deming

Autorregressivo – AR(1)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

Autorregressivo – AR(1)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi y_{t-1} + \varepsilon_t$$

onde ε_t é um ruído branco.

Autorregressivo – AR(1)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi y_{t-1} + \varepsilon_t$$

onde ε_t é um ruído branco. Como temos apenas uma defasagem do erro, este é um AR(1).

Autorregressivo – AR(1)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi y_{t-1} + \varepsilon_t$$

onde ε_t é um ruído branco. Como temos apenas uma defasagem do erro, este é um AR(1). Como seria o modelo com duas defasagens?

Autorregressivo – AR(1)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi y_{t-1} + \varepsilon_t$$

onde ε_t é um ruído branco. Como temos apenas uma defasagem do erro, este é um AR(1). Como seria o modelo com duas defasagens? E com três?

O operador de defasagens (lag operator)

O operador de defasagens (lag operator)

- Operador: L

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t = y_{t-3}$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t = y_{t-3}$
 - $L^5 y_t$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t = y_{t-3}$
 - $L^5 y_t = y_{t-5}$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t = y_{t-3}$
 - $L^5 y_t = y_{t-5}$
 - $L(L^5 y_t)$

O operador de defasagens (lag operator)

- Operador: L
 - $L^j y_t = y_{t-j}$
 - $L^1 y_t = y_{t-1}$
 - $L^3 y_t = y_{t-3}$
 - $L^5 y_t = y_{t-5}$
 - $L(L^5 y_t) = y_{t-6}$

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

- $Lc = c$

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

- $Lc = c$
- $L(y_t + x_t) = y_{t-1} + x_{t-1}$

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

- $Lc = c$
- $L(y_t + x_t) = y_{t-1} + x_{t-1}$
 - $(L^i + L^j)y_t = y_{t-i} + y_{t-j}$

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

- $Lc = c$
- $L(y_t + x_t) = y_{t-1} + x_{t-1}$
 - $(L^i + L^j)y_t = y_{t-i} + y_{t-j}$
- $L(y_t x_t) = y_{t-1} x_{t-1}$

O operador de defasagens (lag operator)

Propriedades (Enders 2014; Bueno 2012):

- $Lc = c$
- $L(y_t + x_t) = y_{t-1} + x_{t-1}$
 - $(L^i + L^j)y_t = y_{t-i} + y_{t-j}$
- $L(y_t x_t) = y_{t-1} x_{t-1}$
- $L^{-1}y_t = y_{t+1}$ (lead operator)

AR(1) e o operador de defasagens

Represente o processo AR(1) descrito anteriormente utilizando o operador de defasagens.

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)}$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)} = \left(1 + \phi L + \phi^2 L^2 + \dots\right) (c + \varepsilon_t)$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)} = (1 + \phi L + \phi^2 L^2 + \dots)(c + \varepsilon_t) \iff$$

$$y_t = (1 + \phi L + \phi^2 L^2 + \dots)c + (1 + \phi L + \phi^2 L^2 + \dots)\varepsilon_t$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)} = \left(1 + \phi L + \phi^2 L^2 + \dots\right) (c + \varepsilon_t) \iff$$

$$y_t = \left(1 + \phi L + \phi^2 L^2 + \dots\right) c + \left(1 + \phi L + \phi^2 L^2 + \dots\right) \varepsilon_t \iff$$

$$y_t = \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)} = \left(1 + \phi L + \phi^2 L^2 + \dots\right) (c + \varepsilon_t) \iff$$

$$y_t = \left(1 + \phi L + \phi^2 L^2 + \dots\right) c + \left(1 + \phi L + \phi^2 L^2 + \dots\right) \varepsilon_t \iff$$

$$y_t = \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

$$y_t = \mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

onde $\mu = \frac{c}{1 - \phi}$.

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Vamos reescrever o AR assumindo que $|\phi| < 1$:

$$y_t = c + \phi y_{t-1} + \varepsilon_t \implies (1 - \phi L)y_t = c + \varepsilon_t$$

como $\frac{1}{(1 - \phi L)} = 1 + \phi L + \phi^2 L^2 + \dots$, temos:

$$y_t = \frac{c + \varepsilon_t}{(1 - \phi L)} = \left(1 + \phi L + \phi^2 L^2 + \dots\right) (c + \varepsilon_t) \iff$$

$$y_t = \left(1 + \phi L + \phi^2 L^2 + \dots\right) c + \left(1 + \phi L + \phi^2 L^2 + \dots\right) \varepsilon_t \iff$$

$$y_t = \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

$$y_t = \mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$$

onde $\mu = \frac{c}{1-\phi}$. Qual tipo de modelo é esse?

A decomposição de Wold (1938)

Qualquer processo y_t que seja **fracamente estacionário** pode ser reescrito como uma função linear de variáveis não-correlacionadas, a_t :

$$y_t = \mu + \sum_{i=0}^{\infty} \phi_i a_{t-i}$$

onde a_t é um ruído branco e $\phi_1 = 1$.

A decomposição de Wold (1938)

Qualquer processo y_t que seja **fracamente estacionário** pode ser reescrito como uma função linear de variáveis não-correlacionadas, a_t :

$$y_t = \mu + \sum_{i=0}^{\infty} \phi_i a_{t-i}$$

onde a_t é um ruído branco e $\phi_1 = 1$.

Ou seja, qualquer processo **linear** possui uma representação MA(∞).

- Não podemos estimar infinitos coeficientes.

- Não podemos estimar infinitos coeficientes.
- Portanto, nós colocamos restrições.

- Não podemos estimar infinitos coeficientes.
- Portanto, nós colocamos restrições.
- No processo AR trataremos sobre o padrão de decaimento dos coeficientes ϕ .

- Não podemos estimar infinitos coeficientes.
- Portanto, nós colocamos restrições.
- No processo AR trataremos sobre o padrão de decaimento dos coeficientes ϕ .
- No processo MA, não precisamos impor restrições.

Um AR(1) é (fracamente) estacionário?

Voltando à estacionariedade do AR(1)...

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E \left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j} \right]$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j})$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j}) = \mu.$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j}) = \mu.$$

- Segundo momento:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j}) = \mu.$$

- Segundo momento:

$$\text{Var}[y_t] = E\left[(y_t - \mu)^2\right]$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j}) = \mu.$$

- Segundo momento:

$$\text{Var}[y_t] = E\left[(y_t - \mu)^2\right] = E\left[\sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right]^2$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Expectativa incondicional:

$$E[y_t] = E\left[\mu + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right] = \mu + \sum_{j=0}^{\infty} \phi^j E(\varepsilon_{t-j}) = \mu.$$

- Segundo momento:

$$\text{Var}[y_t] = E[(y_t - \mu)^2] = E\left[\sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}\right]^2 = \sum_{j=0}^{\infty} \phi^{2j} E[\varepsilon_{t-j}^2] = \frac{\sigma^2}{1 - \phi^2}.$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Autocovariância:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Autocovariância:

$$E[(y_t - \mu)(y_{t-j} - \mu)] = E\left[\left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s}\right) \left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s-j}\right)\right] =$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Autocovariância:

$$\begin{aligned} E[(y_t - \mu)(y_{t-j} - \mu)] &= E\left[\left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s}\right) \left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s-j}\right)\right] = \\ &= \sigma^2 (\phi^j + \phi^{j+2} + \phi^{j+4} + \dots) = \left(\frac{\phi^j}{1 - \phi^2}\right) \sigma^2 \\ &\quad (1) \end{aligned}$$

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Autocovariância:

$$\begin{aligned} E[(y_t - \mu)(y_{t-j} - \mu)] &= E\left[\left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s}\right) \left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s-j}\right)\right] = \\ &= \sigma^2 (\phi^j + \phi^{j+2} + \phi^{j+4} + \dots) = \left(\frac{\phi^j}{1 - \phi^2}\right) \sigma^2 \\ &\quad (1) \end{aligned}$$

- Autocorrelação:

Um AR(1) é (fracamente) estacionário? (Bueno 2012)

- Autocovariância:

$$\begin{aligned} E[(y_t - \mu)(y_{t-j} - \mu)] &= E\left[\left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s}\right) \left(\sum_{s=0}^{\infty} \phi^s \varepsilon_{t-s-j}\right)\right] = \\ &= \sigma^2 (\phi^j + \phi^{j+2} + \phi^{j+4} + \dots) = \left(\frac{\phi^j}{1 - \phi^2}\right) \sigma^2 \end{aligned} \quad (1)$$

- Autocorrelação:

$$\rho_j = \frac{\left(\frac{\phi^j}{1 - \phi^2}\right) \sigma^2}{\frac{\sigma^2}{1 - \phi^2}} = \phi^j, j = 1, 2, \dots \quad (2)$$

Um $AR(1)$ é (fracamente) estacionário? (Bueno 2012)

Mas e então, o $AR(1)$ é um processo
(fracamente) estacionário?

AR(2)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

AR(2)

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

onde ε_t é um ruído branco.

Um $AR(2)$ é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um $AR(2)$ é dada por:

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$E[y_t] = c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$E[y_t] = c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies$$

$$E[y_t] \equiv \mu =$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Portanto, temos:

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Portanto, temos:

$$y_t - \mu =$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Portanto, temos:

$$y_t - \mu = \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \varepsilon_t$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Portanto, temos:

$$\begin{aligned} y_t - \mu &= \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \varepsilon_t \\ E[(y_t - \mu)(y_{t-j} - \mu)] \end{aligned}$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

A esperança incondicional de um AR(2) é dada por:

$$\begin{aligned} E[y_t] &= c + \phi_1 E[y_{t-1}] + \phi_2 E[y_{t-2}] + E[\varepsilon_t] \implies \\ E[y_t] &\equiv \mu = \frac{c}{1 - \phi_1 - \phi_2}. \end{aligned}$$

Portanto, temos:

$$\begin{aligned} y_t - \mu &= \phi_1 (y_{t-1} - \mu) + \phi_2 (y_{t-2} - \mu) + \varepsilon_t \\ E[(y_t - \mu)(y_{t-j} - \mu)] &= \phi_1 E[(y_{t-1} - \mu)(y_{t-j} - \mu)] + \\ &+ \phi_2 E[(y_{t-2} - \mu)(y_{t-j} - \mu)] + E[\varepsilon_t (y_{t-j} - \mu)]. \end{aligned}$$

Um AR(2) é (fracamente) estacionário? (Bueno 2012)

Finalmente, temos que a autocovariância (γ_j) do processo AR(2) segue um AR(2):

$$\gamma_j = \phi_1 \gamma_{j-1} + \phi_2 \gamma_{j-2}, j = 1, 2, \dots$$

E, portanto, para a autocorrelação:

$$\rho_j = \phi_1 \rho_{j-1} + \phi_2 \rho_{j-2}, j = 1, 2, \dots$$

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

Seja y_t uma variável aleatória tal que o seu processo estocástico é dado por:

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t$$

onde ε_t é um ruído branco.

Veja se um $AR(p)$ é (fracamente) estacionário em Bueno (2012).

Veja se um $AR(p)$ é (fracamente) estacionário em Bueno (2012).
Mas dada a decomposição de Wold, o que podemos inferir?

- Expectativa incondicional:

- Expectativa incondicional:

$$E[y_t] = \frac{c}{1 - \phi_1 - \phi_2 - \cdots - \phi_p}$$

- Expectativa incondicional:

$$E[y_t] = \frac{c}{1 - \phi_1 - \phi_2 - \cdots - \phi_p}$$

- Equação característica:

- Expectativa incondicional:

$$E[y_t] = \frac{c}{1 - \phi_1 - \phi_2 - \dots - \phi_p}$$

- Equação característica:

$$1 - \phi_1\lambda - \phi_2\lambda^2 - \dots - \phi_p\lambda^p = 0$$

- Expectativa incondicional:

$$E[y_t] = \frac{c}{1 - \phi_1 - \phi_2 - \dots - \phi_p}$$

- Equação característica:

$$1 - \phi_1\lambda - \phi_2\lambda^2 - \dots - \phi_p\lambda^p = 0$$

O que precisamos para que exista convergência?

Leia os **livros** e os **artigos**, não
fique só com os slides!!!!

Bueno, Rodrigo De Losso da Silveira. 2012. *Econometria de Séries Temporais*. Cengage Learning.

Enders, Walter. 2014. "Applied Econometric Time Series Fourth Edition." *New York (US): University of Alabama*.

Wold, Herman. 1938. "A Study in the Analysis of Stationary Time Series." PhD thesis, Almqvist & Wiksell.